Titanic: Aplicando método EDA para o resumo dos dados

Resumo

Este caso de estudo tem como objetivo criar uma base sólida utilizando o método **EDA** para a fomentação de hipóteses que por sua vez contribuirá com uma análise Preditiva mais eficiente. Tendo isso em mente, é valido ressaltar que apesar de todo este processo inicial ter como objetivo a análise preditiva este caso de estudo apenas focará na análise descritiva do caso.

Considerações Iniciais

Ao ter um primeiro contato com análise de dados é muito comum se sentir perdido. Perguntas como "por onde devo começar" ou "quais medidas usar?" são extremamente normais, isso porque quando não temos um processo bem definido tudo se torna um caos. Dada a necessidade de se definir um processo inicial e fundamental sobre esta etapa da análise descritiva, surgiu em 1977 por **John Tukey** o que conhecemos como método **EDA**, este método tem como objetivo utilizar três etapas bem fundamentas para a criação de processos mais sofisticados como análise preditivas, na verdade é necessário ter um processo EDA em qualquer estado inicial de uma análise. Com o objetivo de criar hipóteses e formar ideias para futuros processos iremos utilizar o que este método tem de melhor para nos oferecer.

Nota!

Toda análise aqui feita estará contida no campo das **analises descritivas**, logo será valido salientar que neste primeiro relatório não teremos nenhum assunto relacionado sobre modelos probabilísticos.

Contexto

Para iniciar este caso de estudo é necessário implicar um contexto sobre o mesmo. Primeiro neste caso de estudo iremos utilizar um conjunto de dados bem conhecido – na verdade acredito que o mesmo já foi utilizado de forma bem exaustiva –, que é o conjunto de dados do Titanic, apesar de ter algumas hipóteses já formadas acredito que ainda é muito cedo impor algo aqui.

Criação do dicionário

Antes de iniciar qualquer projeto envolvendo dados é necessário criar um dicionário sobre o conjunto de dados. O dicionário tem como objetivo ser uma espécie de "registro inicial" do conjunto de dados, nele descrevemos as característica atribuídas a uma variável, desde o tipo da variável até quais dados ela pode vir representar. [dicionário]

Tratamento dos dados

Ao iniciar o tratamento dos dados é necessário entender como o conjunto de dados está se portando com isso, precisamos entender o conjunto total de casos e quantas variáveis temos. Fazer este tipo de processo permite entender se os valores atribuídos as variáveis estão de acordo com as definições feitas no dicionário e assim corrigir caso exista alguma incompatibilidade.

```
df.shape
```

```
(847, 12)
```

Inicialmente temos 847 registros e 12 variáveis, isso porque no processo de **tratamento, padronização** e **normalização** ocorrem processos de criação de variáveis a partir de variáveis já existentes. Dando continuidade ao processo, agora será necessário entender se os tipos aplicados nas variáveis condizem com aquilo que foi definido no dicionário, se caso estiver, basta seguir para o próximo passo, que é entender a existência de **valores nulos**[1] e **outliers** [2].

```
df.dtypes
```

```
PassengerId      int64
Survived         int64
Pclass           int64
Name               str
Sex                str
Age            float64
SibSp            int64
Parch            int64
Ticket             str
Fare           float64
Cabin              str
Embarked           str
dtype: object
```

Existem alguns pontos a serem observados aqui, o primeiro é que por se tratar de um conjunto de dados com origem estrangeira todas as variáveis e valores que a compõem estão em inglês, o segundo ponto e de extrema importância é em conjunto de dados que possuam dados sensíveis como nome, cpf, telefone entre outros devem ser tratados – acredito que na maioria das vezes até mesmo excluídos –, logo ao prestar atenção nas variáveis acima temos a variável **nome**, que por sua vez é um dado sensível, com isso foi necessário excluir a mesma para assim garantir a segurança do indivíduo e seus dados.

Tendo em mente estes dois pontos agora podemos enxergar os valores nulos de cada variável.

```
df.isnull().sum()
```

```
Id_passageiro                0
Sobrevivente                 0
Classe                       0
Sexo                         0
```

1 Representam a ausência de valores e muitas vezes são representados por zero de forma errônea
2 Representam valores atípicos tanto para escalas massivas quanto para diminutas

```
Sexo (Nominal)                0
Idade                       177
Irmaos_conjunges              0
Pais_Filhos                   0
Bilhete                       0
Custo_Bilhete                 0
Cabine                        0
Porto_embarque                2
Porto_embarque (Ordinal)      2
dtype: int64
```

Como visto acima, a variável **nome** foi excluída do conjunto de dados e todas as outras foram traduzidas – o conteúdo também foi em certa medida traduzido –, agora é necessário entender sobre que será feita em relação às variáveis com valores nulos existentes. Qualquer um poderia pensar que basta que as mesmas sejam retiradas do conjunto de dados, porém como estamos lidando com dados que tratam de questões sensíveis, qualquer informação retirada pode ser um grave erro – com exceção dos dados que por sua vez são de fato ruídos, como registros com características totalmente desalinhadas com a natureza do conjunto, afinal seria estranho ter um registro que contenha informações de uma pizzaria –, e também deve ser considerado a proporção que estes dados ocupam no conjunto inteiro como por exemplo a variável **idade** represente 21% dos dados do conjunto, logo remove-las é realmente um erro.

Agora que a proporção dos dados nulos já é conhecida cabe a nós definir o que sera feito a respeito. Uma característica bem interessante dos dicionários de dados é que eles também permitem definir se uma variável terá ou não a possibilidade de aplicação para nulos e quais serão o rótulos aplicáveis às mesmas. De acordo com a definição do dicionário, todas as variáveis foram rotuladas como "Não Identificável", com isso podemos concluir que esta tudo certo correto? Na verdade temos meio passo concluído, acontece que quando atribuímos este rótulo para a variável idade a mesma passa a se portar como um tipo **Object**[3], logo se torna necessário outro método de aplicação para a variável idade.

Ao utilizar o **numpy** se torna possível aplicar um valor "especial" para os nulos contidos na variável idade.

```
df['Idade'] = df['Idade'].fillna(np.nan)
```

Bom outras aplicações iniciais também foram feitas como, traduzir o nome das variáveis e seus respectivos valores e a criação de duas novas variáveis do tipo **encoder** para o mapeamento das variável **Sexo** e **Porto_Embarque.**

3 Toda variável que não for passível de identificação numérica irá se portar como uma Object, todo Object é uma representação de uma string.

Entendendo a Distribuição dos Dados

Logo depois que o processo inicial é finalizado passa a ser necessário entender como a estrutura se comporta – no quesito distribuição dos dados –, tendo isso em mente é preciso definir uma variável que permita enxergar tal comportamento aplicado a cada indivíduo, essa variável precisa ser destingível, de maneira que visualizar a distribuição através da mesma permita formular hipóteses sobre o conjunto de dados. A variável determinada para nosso caso sera a **Idade** e para entender melhor o seu comportamento foi necessário criar uma tabela de frequência da mesma – sua versão digital também pode ser acessada através do arquivo [recursos].

Tabela de frequência de distribuição

Faixa	Frequência Absoluta	Frequência Relativa	Frequência Acumulada
6 - 12	25	3.7	3.7
13 - 17	44	6.0	10.3
18 - 29	271	40.4	50.7
30 - 59	304	45.4	96.1
60 - 80	26	3.9	100
Total	670	100	

O primeiro ponto a se notar aqui é que o número total de observações da tabela não coincide com o número total do conjunto de dados, porém ao olhar a tabela mais uma vez é possível ver que os 177 indivíduos com idade nula não foram impostos na tabela. Outro ponto a ser observado é que a escolha do número total de classes foi igual a 5, porém não existe uma hemogenia quanto a amplitude das classes.

Obs!

Crianças com idade menor ou igual a 5 anos foram tiradas do conjunto de dados atual para um subconjunto.

Particularidade da variável idade

No inicio foi dito que a variável idade era do tipo F**loat**, o que é de se estranhar pois normalmente não dizemos que temos 23 anos e 4 meses, porém ao observar os dados é possível notar que existem indivíduos com idade menor que zero, porém isso não é um erro, pois bebes tiveram suas idades registradas com 0.XX, com isso podemos finalizar este tópico? Na verdade não pois, alguns indivíduos com idade avançada também possuem em suas casas decimais um valor maior que zero, porém basta arredondar e normalizar o padrão para a variável idade.

Aplicando medidas ao conjunto de dados

Tendo já criado a tabela de frequência dos dados, passa a ser possível visualizar os mesmos, porém antes de iniciar qualquer processo de visualização, se torna necessário a aplicação de medidas estatísticas, conhecidas como medidas de **Tendência Central**, **Dispersão** e **Formato**. Aplicar estas medidas ao conjunto de dados também permite com que se entenda melhor a natureza dos dados, possibilitando assim formar hipóteses sobre os mesmos.

O primeiro ponto de partida será usar alguma medida que permita encontrar o meio do conjunto de dados, este tipo de medida pertence ao primeiro grupo já dito acima (Tendência Central), neste grupo temos as seguintes medidas: média, mediana, moda, quantis, quartis e decis. Existe uma grande preocupação quando se é utilizado a média, pois a mesma tende a ser instável quando em um conjunto temos valores que ainda se encaixam no grupo, porém seus valores tendem a ser maiores. Acredito que aí surge a pergunta "então por que estes valores não são removidos?", bom acontece que os mesmos não são outliers, eles apenas representam casos que estejam bem acima daquilo que consideramos como "normal" ou melhor aquilo que consideramos como a "média".

Ao aplicar o calculo da média e mediana é possível visualizar resultados com uma diferença pequena, logo não é preciso apenas limitar ao uso da mediana, afinal a média apresentou um resultado satisfatório.

Mediana

```
df['Idade'].median()
```

```
np.float64(29.0)
```

Média

```
df['Idade'].mean().round()
```

```
np.float64(31.0)
```

Também é possível verificar a idade máxima e mínima do conjunto de dados, assim conseguimos ter uma pré-visualização e verificação de possíveis outliers.

Idade Mínima

```
df['Idade'].min()
```

```
np.float64(6.0)
```

Idade Máxima

```
df['Idade'].max()
np.float64(80.0)
```

Outras medidas também serão aplicadas, como a definição dos Quartis, Intervalo Interquartil, Intervalo Admissível e Coeficiente Bowley.

Quartis

```
Q1 = df['Idade'].quantile(0.25)
Q2 = df['Idade'].quantile(0.50)
Q3 = df['Idade'].quantile(0.75)
```

Intervalo Interquartil

```
IQR = Q3 – Q1
```

```
np.float64(17.0)
```

Intervalo Admissível

```
IA = [Q1 - (1.5*IQR), Q2 + (1.5 * IQR)]
[np.float64(-3.5), np.float64(54.5)]
```

Coeficiente de Bowley

```
Cb = round(((Q3 - Q2) - (Q2- Q1))/ (IQR), 2)
np.float64(0.18)
```

Desvio Padrão

```
df['Idade'].std().round()
np.float64(13.0)
```

Bom, agora sabemos que temos uma assimetria positiva a direta, e que nosso desvio padrão – o quanto os dados se espalham de acordo com a média –, é igual a 13 e por fim que nosso intervalo interquartil é de **17 anos**, o que significa que os **50% centrais** dos passageiros (aqueles que não são nem os muito jovens, nem os muito idosos) estão distribuídos em uma faixa de idade que abrange **17 anos**."

Visualização dos dados

Agora que já temos as principais medidas já retiradas, podemos visualizar os dados com mais assertividade. Primeiro é preciso entender a proporcionalidade geral de indivíduos de acordo com o seu sexo, para isso será utilizado um gráfico de pizza.

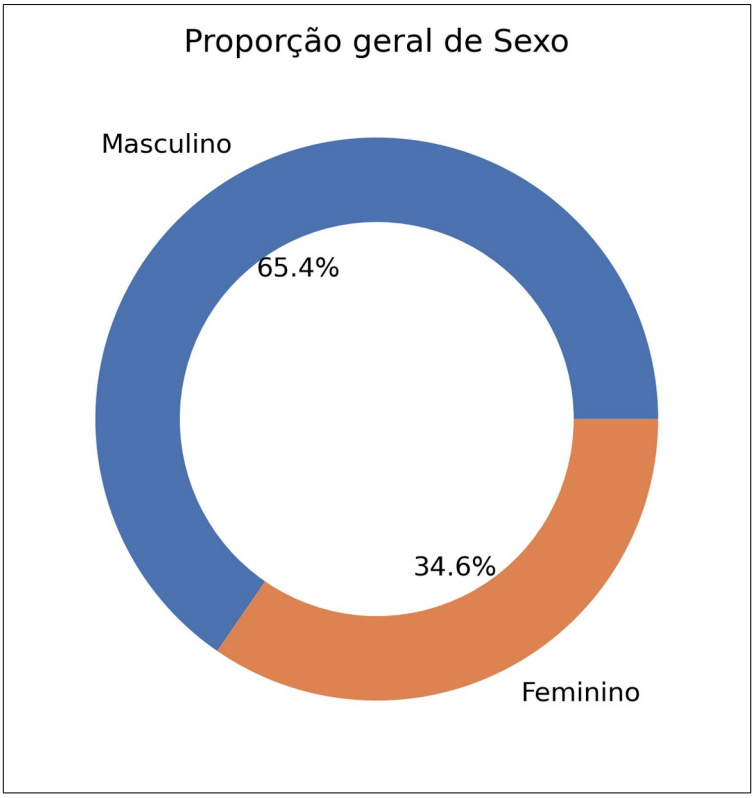

Figure 1: Propoção geral dos indivíduos

Ao visualizar a proporção dos indivíduos de forma geral, conseguimos entender que a sua maioria compõem indivíduos do sexo masculinos, porém apenas entender esta proporção não nos trás muito insight, uma vez que o gráfico não incluí esta mesma proporção de acordo com as faixas etárias já definidas previamente.

Uma forma de sanar esta lacuna é criar um gráfico de barras para entender melhor a proporção dos indivíduos de acordo com sua faixa etária.

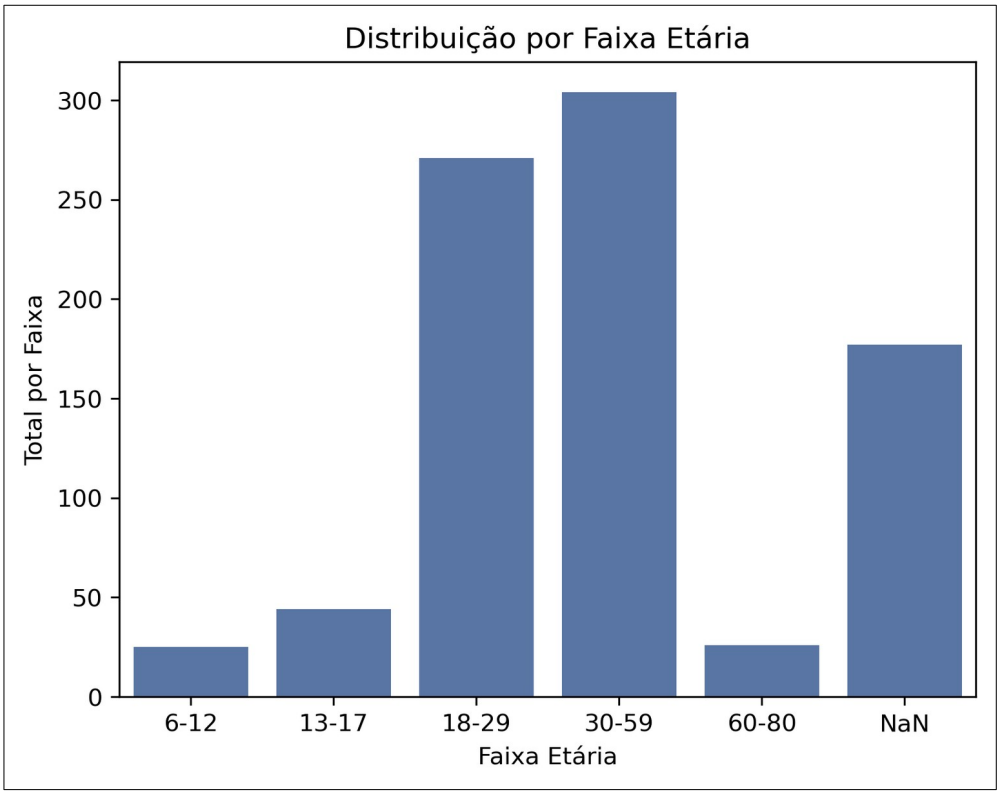

Figure 2: Proporção por faixa etária

Um outro ponto importante será entender sobre a proporção dos indivíduos de acordo com sua classe e porto. Para este caso será um gráfico de barra na horizontal.

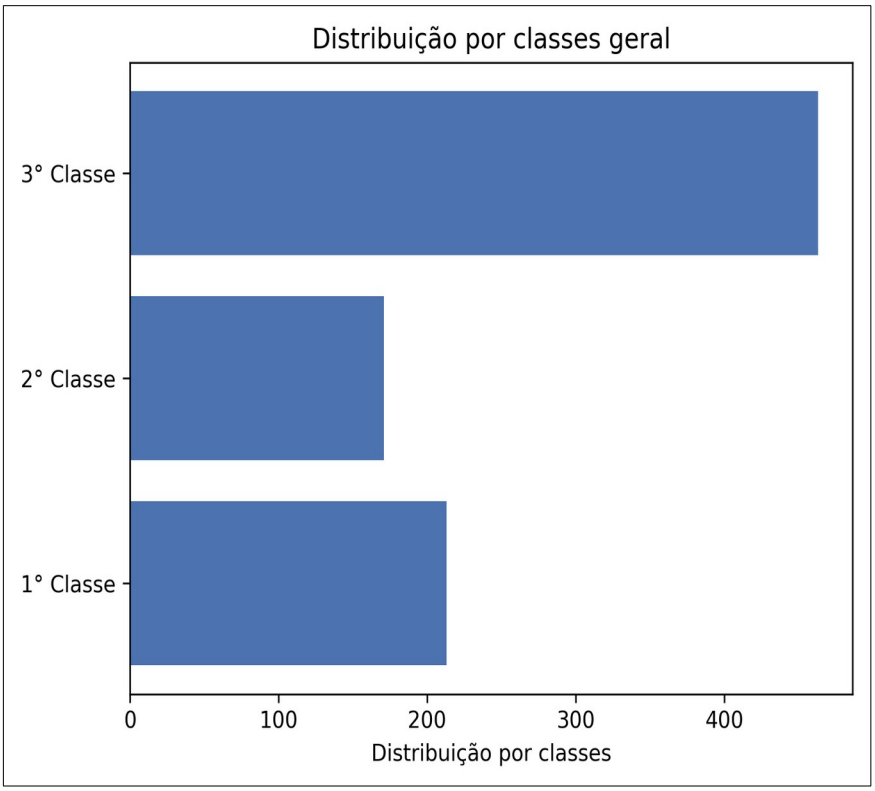

Figure 3: Distribuição por classes

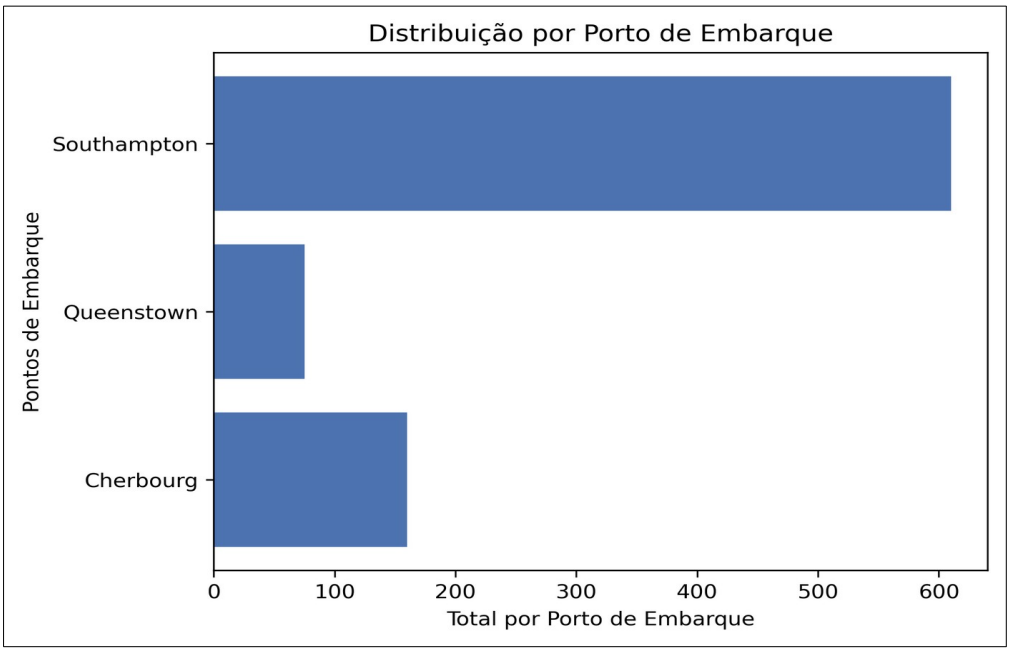

Figure 4: Distribuição por porto de embarque

Nota!

Em todos os gráficos gerados acima não foi utilizado os 177 registros com idade nula.

Como dito anteriormente, este conjunto de dados possui uma assimetria positiva a direita, porém a mesma só nos faz sentido quando podemos ver em um gráfico.

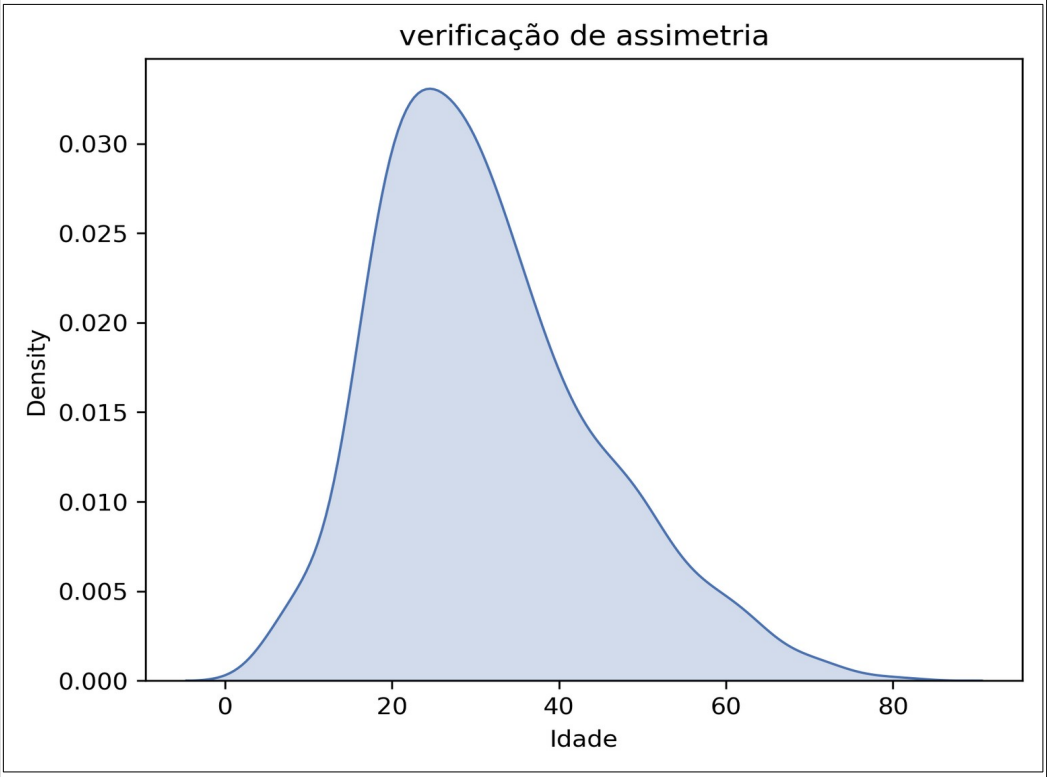

Figure 5: Assimetria positiva a direita

E por último também precisamos entender como o conjunto todo se porta de acordo com os quartis e intervalo admissível.

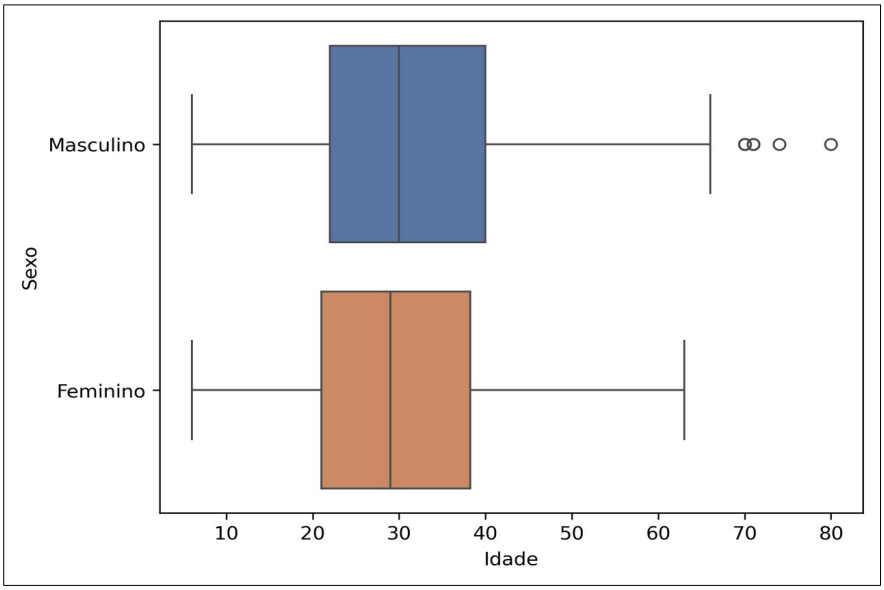

Figure 6: Comportamento do intervalo interquartil

Probabilidades

Com a ajuda dos gráficos acima também podemos ver que as faixas etárias 3 e 4 possuem maior proporção, porém estas duas faixas realmente possuem maior representatividade no quesito sobrevivência? Elas realmente são representativas? A preferência de uso para os botes – mulheres e crianças primeiro – realmente fio efetiva? Bom, isso tudo pode ser respondido com gráficos e probabilidades condicionais.

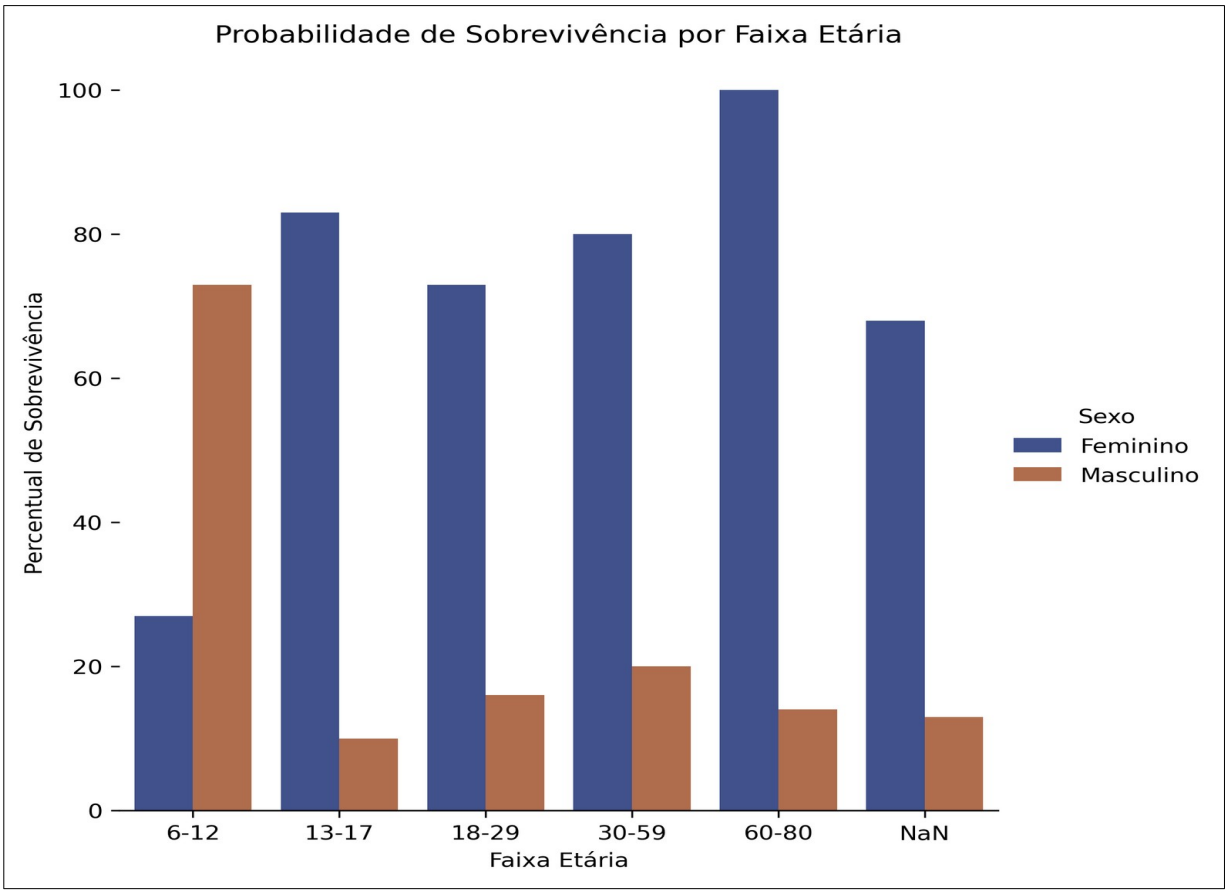

Aparentemente é possível confirmar que a regra de uso dos botes teve efeito significativo, uma vez que indivíduos do sexo feminino tiveram maior probabilidade de sobrevivência, apesar de tudo o mesmo parece não ter sido aplicado com a primeira faixa onde indivíduos tiveram maior chance de sobrevivência. Quanto a este evento é muito impreciso dizer o motivo pelo qual essa faixa teve maior taxa de sobrevivência para os indivíduos de sexo masculino, uma das hipóteses seria que o conjunto tenha um número maior para sexo masculino, o que poderia ter influenciado de maneira drástica este resultado.

Podemos também verificar a taxa de sobrevivência de acordo com a classe do indivíduo e seu sexo, e para representar isso o usaremos o mesmo gráfico acima porém com proporções diferentes.

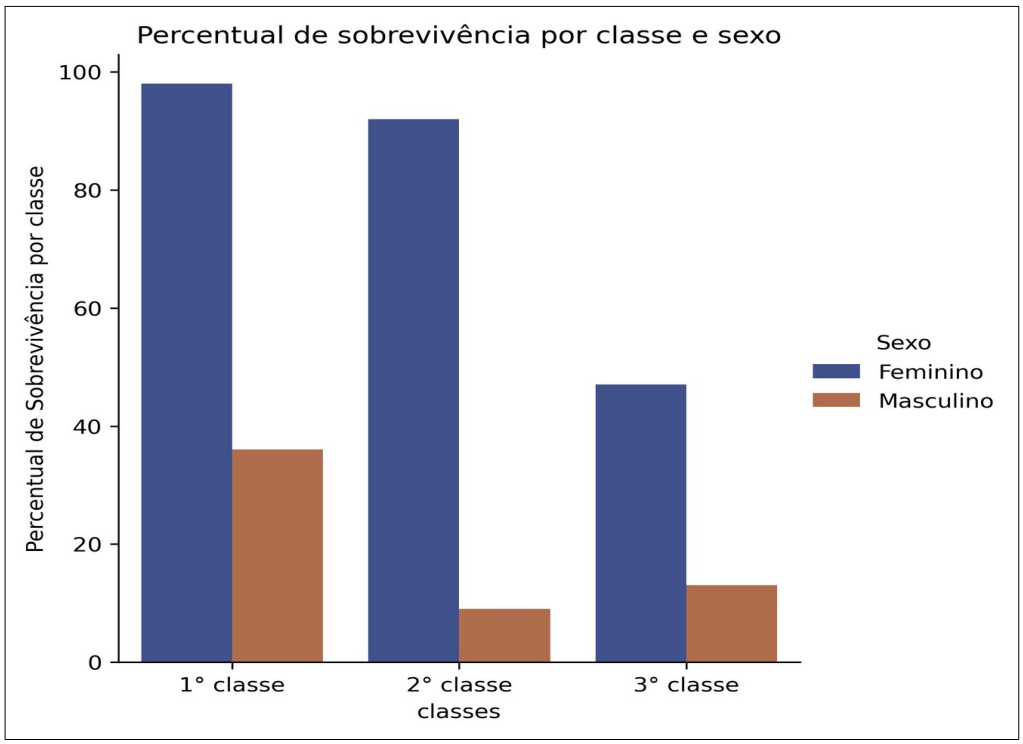

Aqui vemos que indivíduos pertencentes a primeira e segunda classe tiveram maior chance de sobrevivência, porém se compararmos com gráfico anterior, é nítido a percepção de que indivíduos do sexo feminino tiveram maior chance de sobrevivência, o que não ocorre quando aplicamos isso de acordo com as classes, logo poderíamos afirmar que sim houve uma preferência no uso dos botes? A verdade é que isso seria extremamente perigoso uma vez que os indivíduos da terceira classe tinham que percorrer longas distâncias até os botes, outra questão importante a se notar é que não é possível afirmar se os mesmos não tiveram outra causa de morte até se locomoverem aos botes e não por falta dos mesmos.

Também é possível verificar a relação entre idade e taxa de sobrevivência. O gráfico usado para representar esta relação será um tipo de gráfico de dispersão.

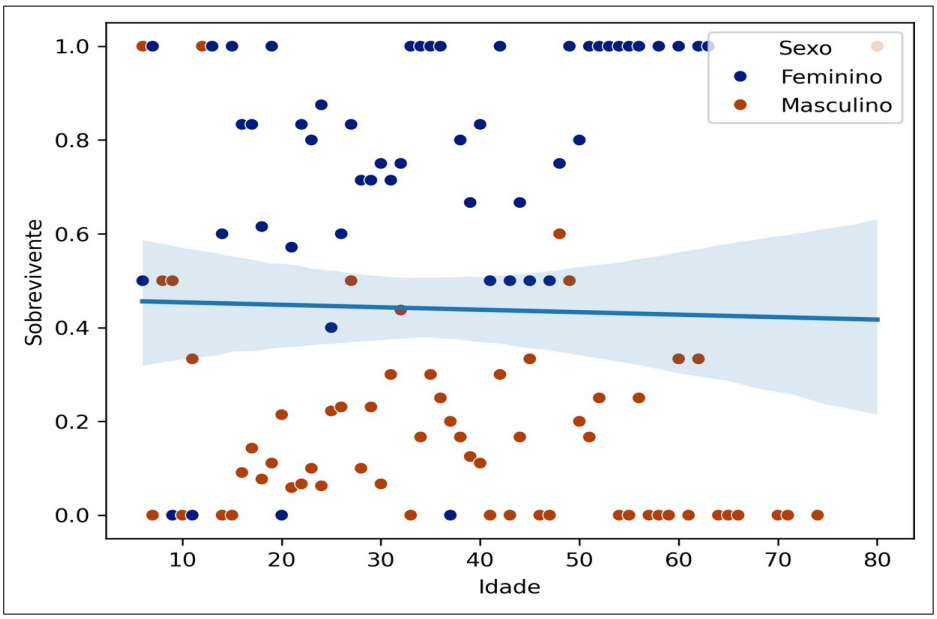

O gráfico acima reforça aquilo que já foi visto anteriormente, onde indivíduos do sexo feminino tendem a ter maior probabilidade de sobrevivência, porém este resultado é bem generalista, o melhor seria entender qual é o comportamento de acordo com cada sexo. Para isso o mesmo gráfico será usado porém as dimensões serão diferentes.

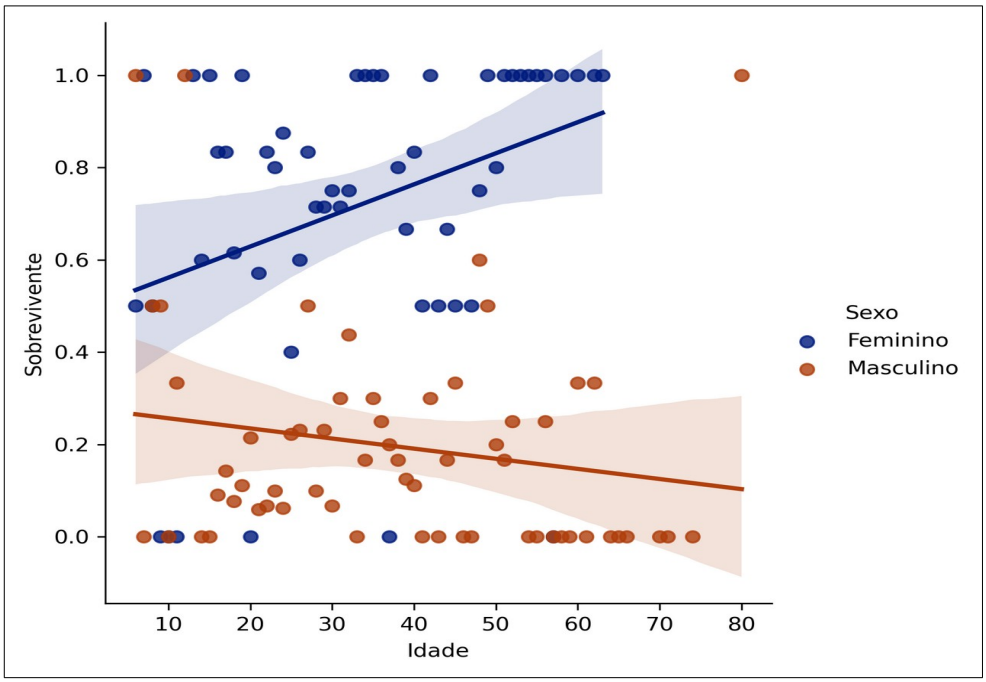

Como já esperado temos uma tendência negativa para o sexo masculino, ou seja, quanto maior a idade dos indivíduos do sexo masculino a probabilidade de sobrevivência tende a ser menor, salve o ultimo ponto no gráfico que é uma exceção.

Analisando o subconjunto

Como dito anteriormente, casos com idade menor ou igual a 5 anos foram separados do conjunto principal e isso foi feito com o intuito de manter o intervalo da primeira classe menor. A seguir veremos alguns gráficos relacionados a este subconjunto e suas medidas.

Ao iniciar a análise neste subconjunto alguns passos serão repetidos como por exemplo quais são as medidas de tendência, dispersão é formato para este subconjunto e por fim, entender melhor o comportamento deste subconjunto através dos gráficos.

Média

```
media_infantil = df_infantil['Idade'].mean().round(2)
```

```
np.float64(2.52)
```

Mediana

```
mediana = df_infantil['Idade'].median().round(2)
```

```
np.float64(2.0)
```

Quartis

```
Q1_infantil = df_infantil['Idade'].quantile(0.25)
```

```
Q2_infantil = df_infantil['Idade'].quantile(0.50)
```

```
Q3_infantil = df_infantil['Idade'].quantile(0.75)
```

```
(np.float64(1.0), np.float64(2.0), np.float64(4.0))
```

Intervalo Interquartil

```
IQR_infantil = Q3_infantil - Q1_infantil
```

```
np.float64(3.0)
```

Intervalo Admissível

```
IA_infantil = [Q1_infantil- (1.5 * IQR_infantil), Q3_infantil + (1.5 *
IQR_infantil)]
```

```
[np.float64(-3.5), np.float64(8.5)]
```

Desvio Padrão

```
desvio_infantil = df_infantil['Idade'].std().round(2)
```

```
np.float64(1.42)
```

Coeficiente de Bowley

```
CB = (((Q3_infantil - Q2_infantil) - (Q2_infantil - Q1_infantil)) /
(IQR_infantil))
```

```
np.float64(0.33)
```

De acordo com as medidas tiradas do subconjunto é possível entender que tanto para média quanto para mediana temos uma diferença não significativa, logo é possível utilizar ambas para este caso.

Um outro ponto é que temos um desvio padrão “contido” ou seja a dispersão para este conjunto não é tão solta, isso por que é valido lembrar que temos a idade mínima para este conjunto igual a 0.44 anos.

Já para a assimetria do conjunto, permanece com uma assimetria positiva a direita, o que pode ser visto com um **kdeplot**.

Visualizando dados do conjunto infantil

Antes de iniciar qualquer visualização dos dados é necessário deixar claro que, por este conjunto se tratar de um subconjunto é sua amostra ser reduzida, foi decido utilizar gráficos para uma visualização mais generalista, uma vez que o propósito deste conjunto é apenas garantir que a regra de uso para os botes foi cumprida. Para além disso não faz sentido criar faixas etárias para este conjunto, pois o mesmo já representa um faixa etária.

Para iniciar será verificado através do gráfico kdeplot, a assimetria dos dados.

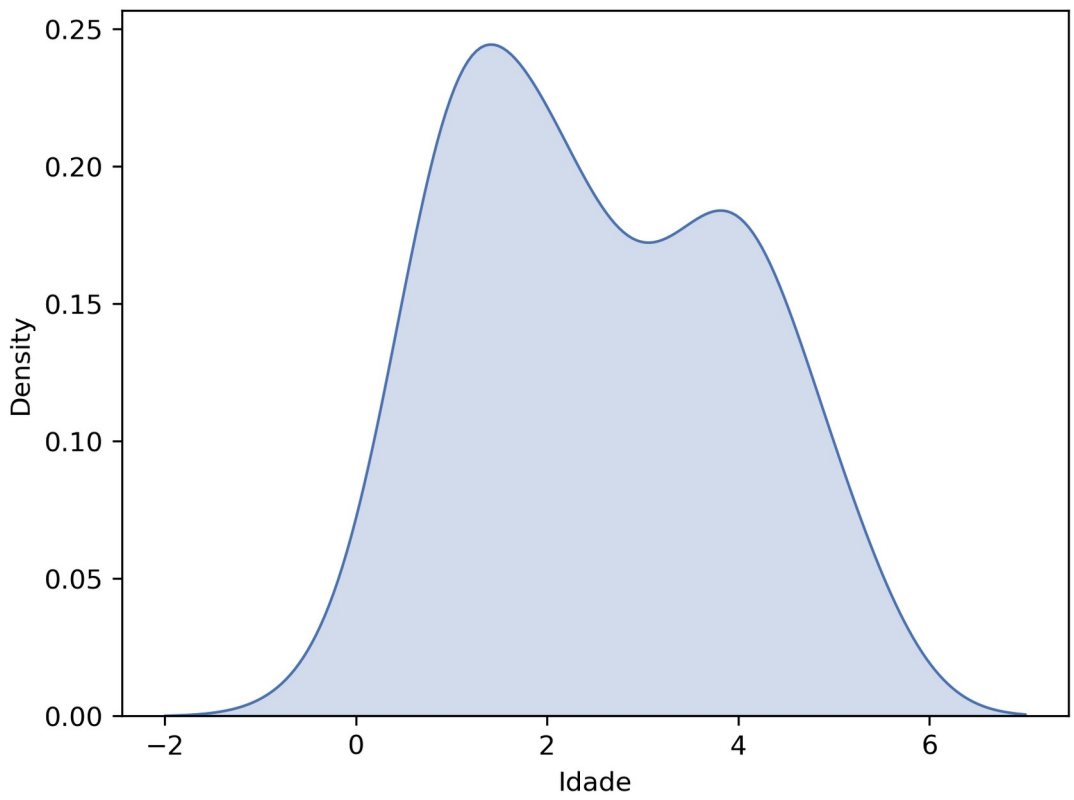

Figure 7: Assimetria para subconjunto infantil

Como já confirmado temos uma assimetria positiva a direita para este conjunto de dados, porém um ponto interessante neste conjunto de dados é que entre 0 a 2 anos temos uma maior concentração dos casos e que também temos uma bimodal para este conjunto.

Entender como o conjunto de dados está se portando é de extrema importância, porém um ponto que não é possível entender é como a distribuição esta aplicada quando aplicamos a variável **sexo** para este conjunto. Para entender será utilizado um gráfico de pizza.

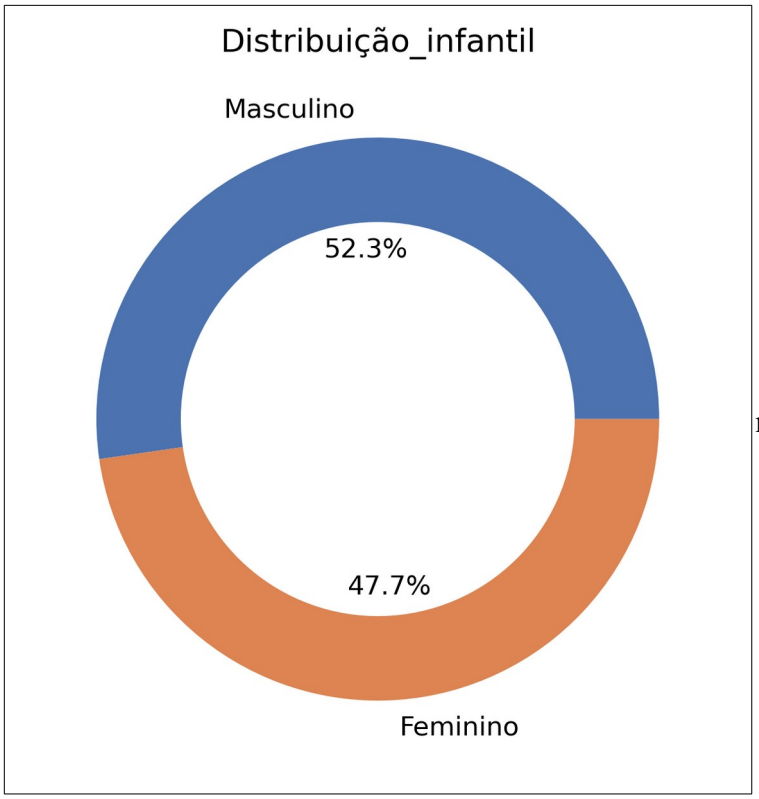

Para este conjunto temos uma proporção mais igualitária isso significa que ambos os grupos tendem a ter representatividades semelhantes para este subconjunto.

Um ponto a ser verificado aqui é se a representatividade realmente é semelhante para os grupos e isso pode ser verificado utilizando a taxa de probabilidade de sobrevivência para os grupos.

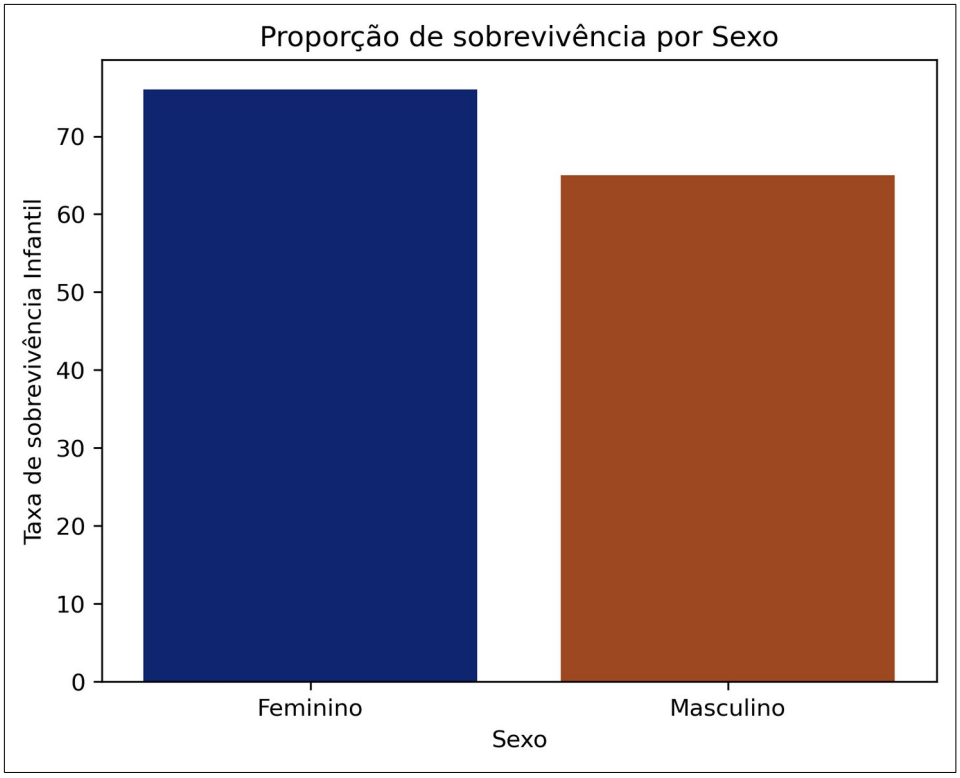

O gráfico acima pode ser bem enganoso uma vez que poderia ser dito que “até mesmo para este conjunto houve prioridade para indivíduos do sexo feminino”, porém apesar do gráfico acima nos dizer que indivíduos do sexo feminino tiveram maior chances de sobrevivência isso por sua vez não diz respeito sobre preferência no uso do bote, isso por que existem outros fatores que infelizmente não podem ser verificados, como por exemplo qual eram os locais em que estes indivíduos estavam? Estavam acompanhados de um adulto? Os mesmos não sobreviveram em decorrência dos botes ou por que sofreram por alguma causa não identificada?

Tendo isso em vista é muito arriscado afirmar que houve maior preferência do uso dos botes para indivíduos do sexo feminino.

Por fim, será verificado o comportamento da sobrevivência dos indivíduos de acordo com sua idade e sexo.

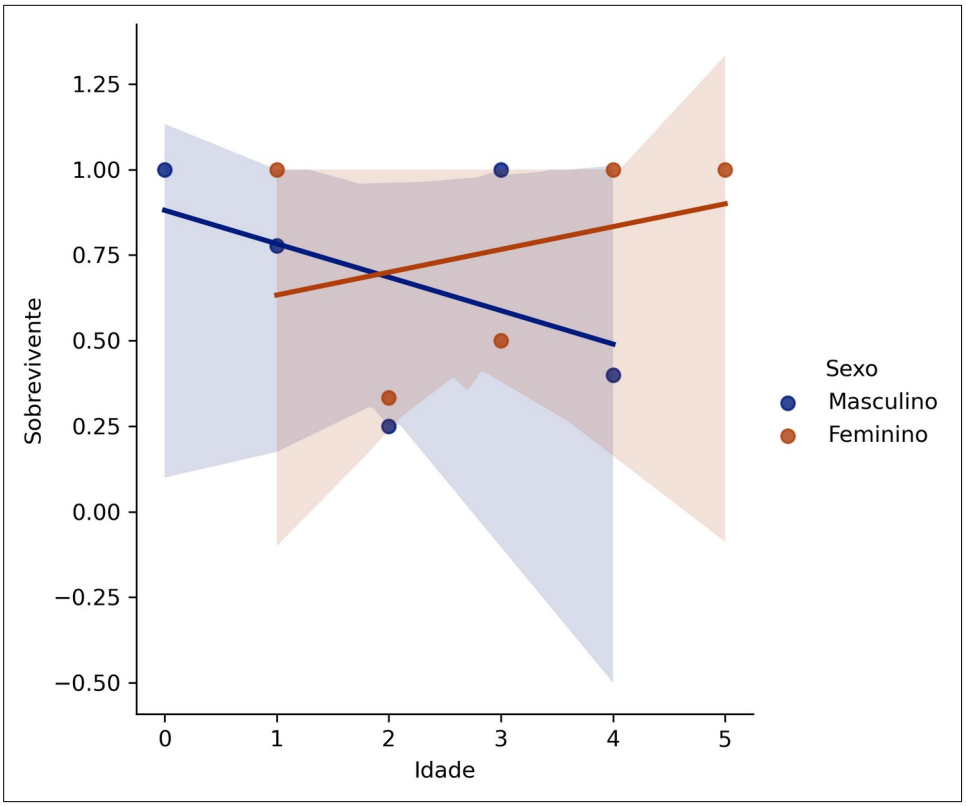

Assim como no conjunto principal o mesmo comportamento se aplica para este subconjunto uma vez que para os indivíduos do sexo feminino possuem uma taxa de sobrevivência crescente o que não se aplica para os indivíduos do sexo oposto.

Considerações Finais

Ao finalizar esta análise inicial foi possível confirmar que de fato indivíduos do sexo feminino tiveram maior chance de sobrevivência e que a preferência de uso dos botes teve seu efeito, mesmo que o total dos indivíduos voltados para tal preferência não foram salvos.

Um ponto importante a ser lembrado é que toda esta análise inicial foi voltada para a análise das variáveis **sexo** e **idade**, o que por sua vez acaba generalizando a questão principal abordada – que no caso é a sobrevivência –, e isso se dá porque outras variáveis que poderiam trazer maiores insights não foram utilizadas, como por exemplo, a companhia de irmãos e cônjuges poderia mudar a perspectiva para a sobrevivência dos indivíduos.

Esta análise voltada para as duas variáveis foi feita apenas para entender o conjunto de dados e sua generalização dos dados foi feita propositalmente, isso porque para uma maior complexidade apenas a análise descritiva não é suficiente, logo o próximo passo será criar modelos probabilísticos que utilizem maior número de variáveis afim de entregar um maior entendimento dos dados.

Um ponto a ser esclarecido aqui está em como identificar os registros com idade nula, para isso será necessário criar um modelo robusto que consigo identificar tais casos e incluí-los em possíveis grupos de faixas etárias.